

アトラクタ再構成のための リザーブコンピューティングの hyperparameter tuning

非線形数理講座

08A19031 大石 悟

カオス力学系

- **決定論的法則に従うが、予測できないほど複雑な軌道をもつ系**

初期値鋭敏性…初期状態が極僅かに異なるだけで、時間発展と共に指数関数的にその差が大きくなる性質 (バタフライ効果)

長期的な予測は原理的に不可能

- 社会・自然界における例
二重振り子, 天候変動, 天体の運動, 神経の発火 (スパイク)

アトラクタ (Attractor)

十分な時間が経過したときに
相空間上の軌道が
引き付けられる一定の集合

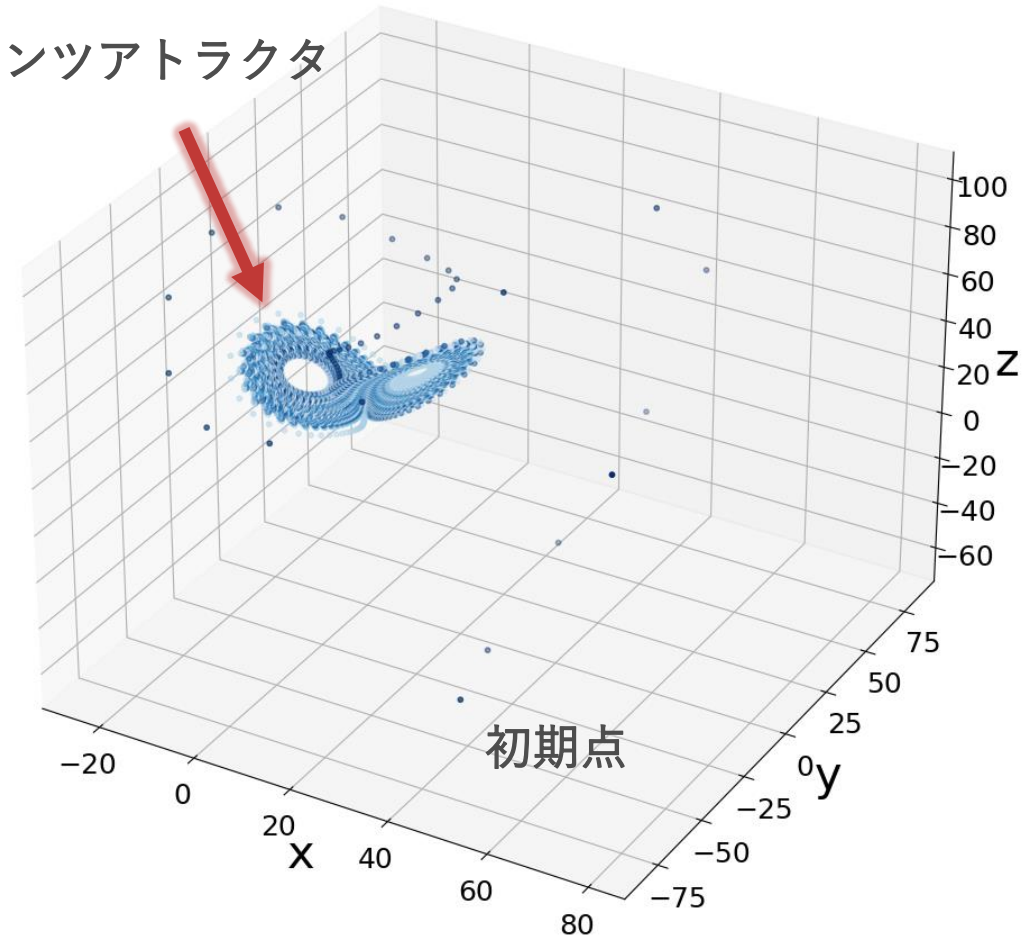
例： Lorenz方程式...大気の大気対流の近似

$$\dot{x} = 10(y - x),$$

$$\dot{y} = x(28 - z) - y,$$

$$\dot{z} = xy - 8z/3.$$


ローレンツアトラクタ



【目的】 アトラクタの性質の再現（アトラクタ再構成）
を達成したカオス時系列予測とその応用

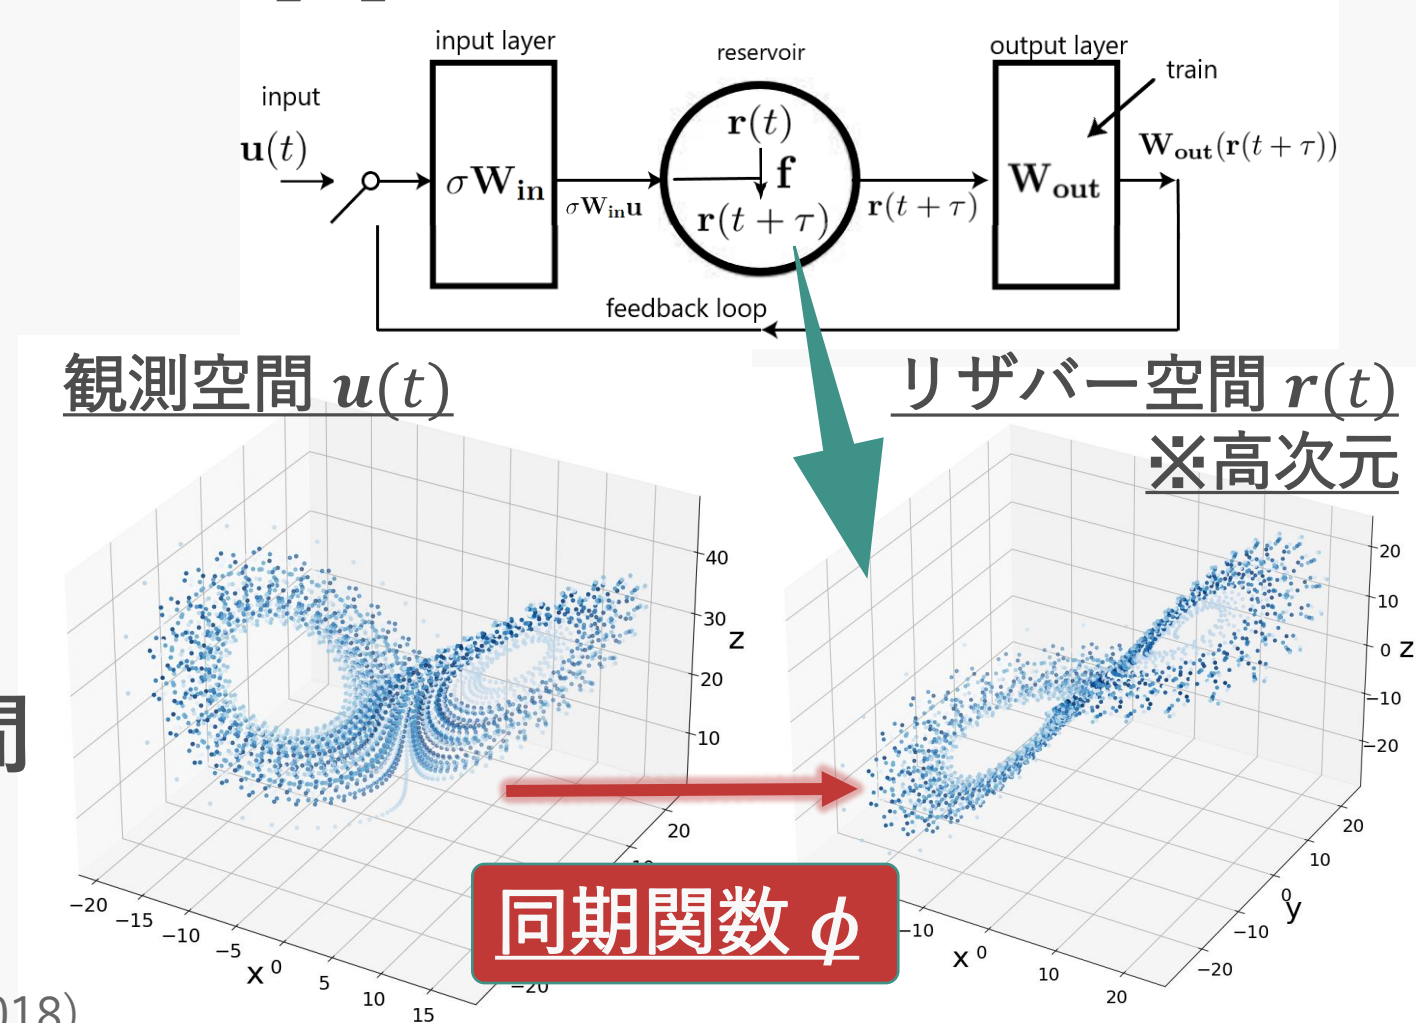
リザーバーコンピューティング (RC) [1]

- カオス力学系の時系列予測に適した機械学習アプローチ
 - 観測時系列 $u(t)$ を 再帰的構造・非線形性 を持った高次元空間 (リザーバー空間) へ入力
 - 入力及び時間発展の更新則: $r(t + \tau) = f[r(t), u(t)]$
 - 正しい時系列を出力するように 出力層だけリッジ回帰 で学習





RCにおけるアトラクタ再構成 [2]

- 観測空間と
リザーバー空間の間に
良い性質をもつ
一般化同期が成立
さらに、同期が安定
- リザーバー空間と観測空間
で統計的性質が一致





アトラクタ再構成の5条件

1. ESP (RCの持つ性質)
2. 弱い一般化同期
(連続同期関数 ϕ が存在)
3. 状態の出力可能性
リザーバーの次元 \gg 観測空間の次元
4. Lyapunovスペクトラムが一致
(アトラクタの統計的特徴量)
5. 同期状態は安定
(横断リアプノフ指数が負)



アトラクタ再構成の 5 条件

1. ESP (RCの持つ性質)
2. 弱い一般化同期
(連続同期関数 ϕ が存在)
3. 状態の出力可能性
リザーバーの次元 \gg 観測空間の次元
4. Lyapunovスペクトラムが一致
(アトラクタの統計的特徴量)
5. 同期状態は安定
(横断リアプノフ指数が負)



研究背景(アトラクタ再構成の 5 条件：2, 3)

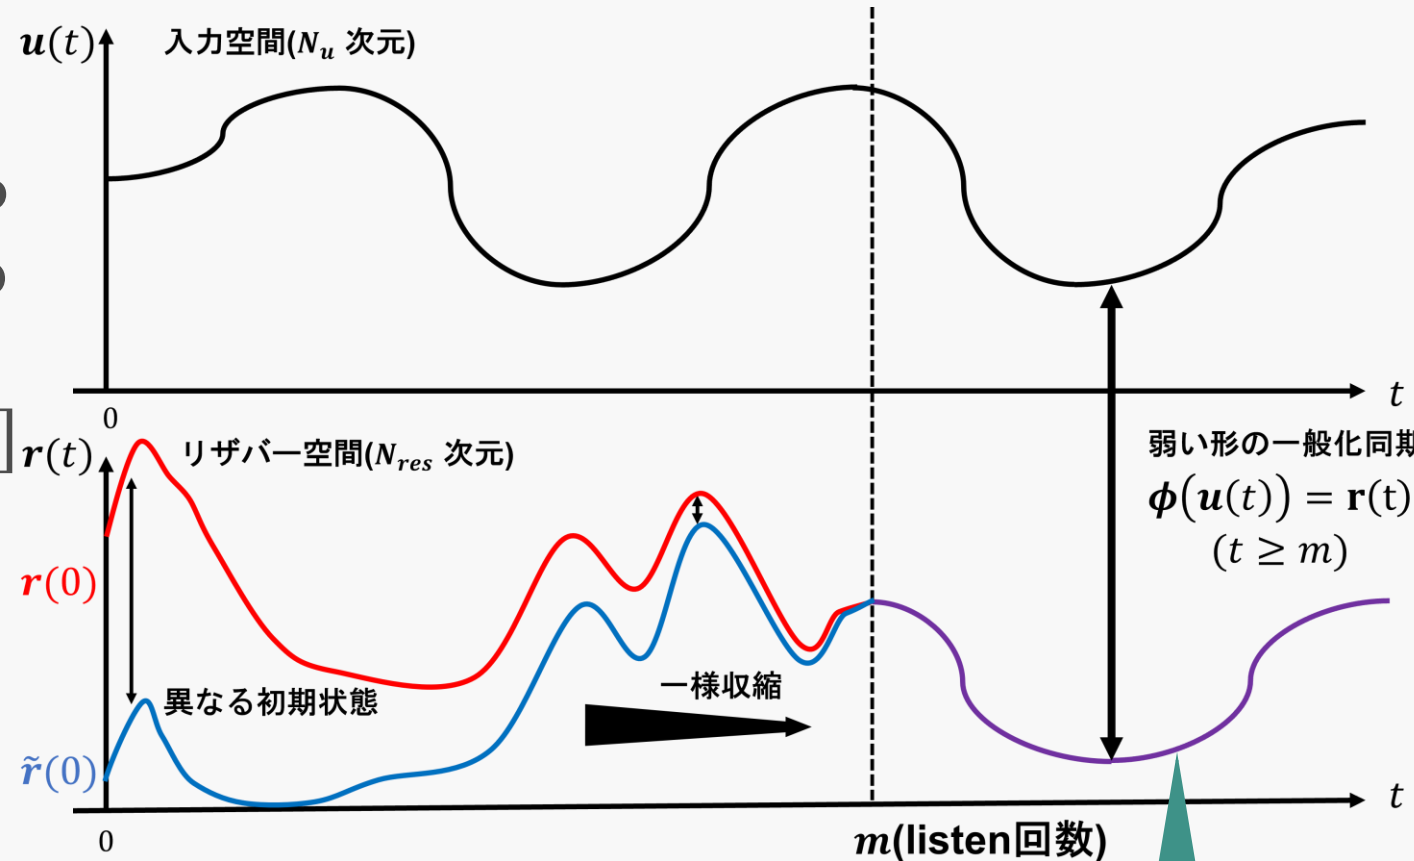
1. ESP

リザーバーの初期状態に依らず、
十分な長さの入力データ列から
リザーバーの状態が一意に決まる

更新則： $r(t + \tau) = f[r(t), u(t)]$
の f が一様収縮性を持つ
 \Rightarrow リザーバーの状態が収束

2. 弱い一般化同期



入力系とリザーバー空間の間に
連続な同期関数 ϕ が存在
 $\phi(u(t)) = r(t) \quad (t \geq m)$



同期状態

アトラクタ再構成の 5 条件

1. ESP (RCの持つ性質) ○
2. 弱い一般化同期
(連続同期関数 ϕ が存在) ○
3. 状態の出力可能性
リザーバー空間の次元 \gg 観測空間の次元
4. Lyapunovスペクトラムが一致
(アトラクタの統計的特徴量)
5. 同期状態は安定
(横断リアプノフ指数が負)



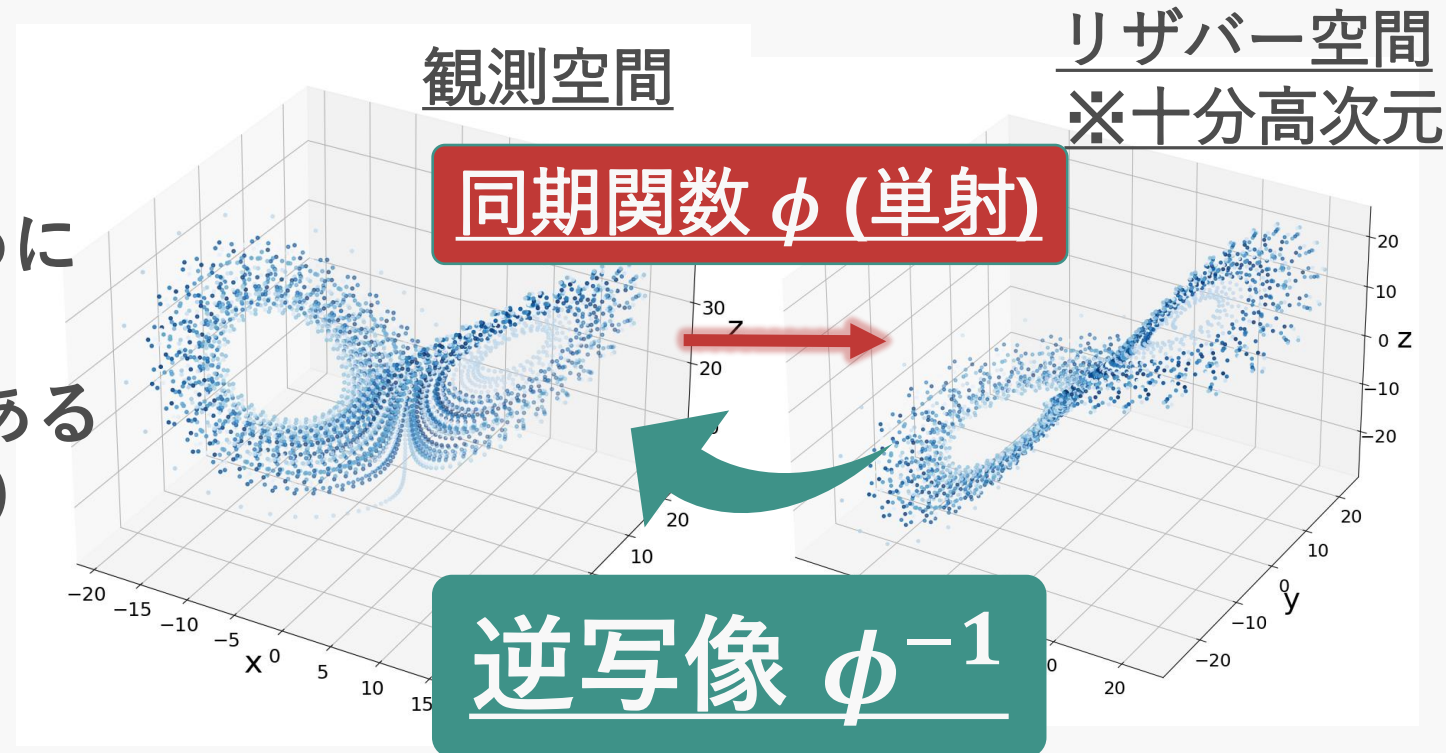
3. 状態の出力可能性

リザーバーの予測が成功するために
同期状態から元の空間への
逆写像 ϕ^{-1} を表現する必要がある
⇒ 同期関数 ϕ が単射(埋め込み)
である必要がある

- 埋め込み定理

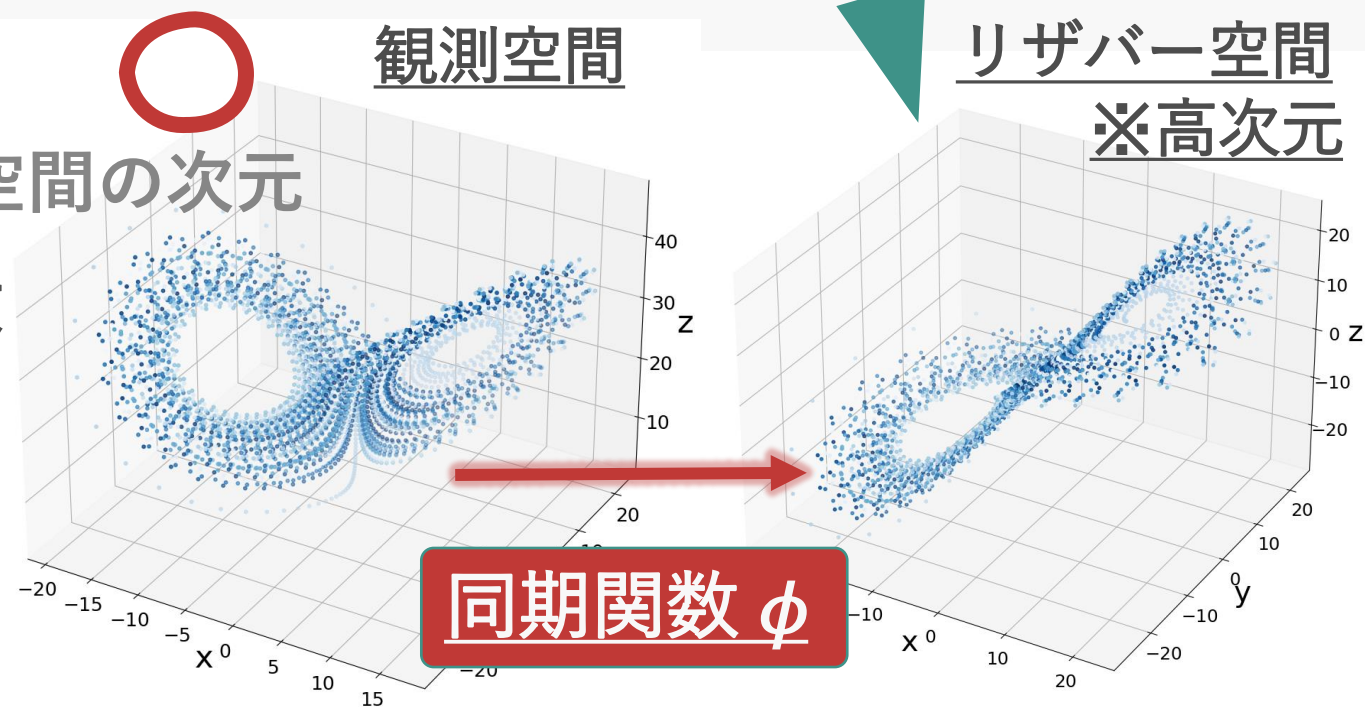

(元のアトラクタの次元) $\times 2 <$ (再構成する空間の次元)
⇒ 埋め込みが存在する

実際は、観測空間の次元 \gg リザーバー空間の次元



アトラクタ再構成の 5 条件

1. ESP (RCの持つ性質) ○
2. 弱い一般化同期
(連続同期関数 ϕ が存在) ○
3. 状態の出力可能性
リザーバー空間の次元 \gg 観測空間の次元 ○
4. Lyapunovスペクトラムが一致
(アトラクタの統計的特徴量)
5. 同期状態は安定
(横断リアプノフ指数が負)



Lyapunovスペクトラム (LS) : アトラクタの統計的特徴量

- Lyapunov指数 λ

$$\|\delta(t)\| \approx \|\delta(0)\| e^{\lambda t}$$

十分近い軌道の指数的分離度


$\lambda_{k+1} < 0$
Lyapunov指数が負
⇒ 指数的に接近

- Lyapunovスペクトラム (LS)

Lyapunov指数 λ_k を降順に並べたもの
相空間の次元と同じ要素数からなる
LSが計算できる

- 学習済みのRCから計算したLSと
元の駆動系のLSを比較

⇒ RCのアトラクタの再構成の程度を評価できる



予備実験(アトラクタ再構成の5条件：4, 5)

4. Lyapunovスペクトラムが一致


学習済みのRCから計算した正・零
Lyapunov指数が真のLSと近い
⇒類似したアトラクタを生成(右下)

5. 同期状態が安定

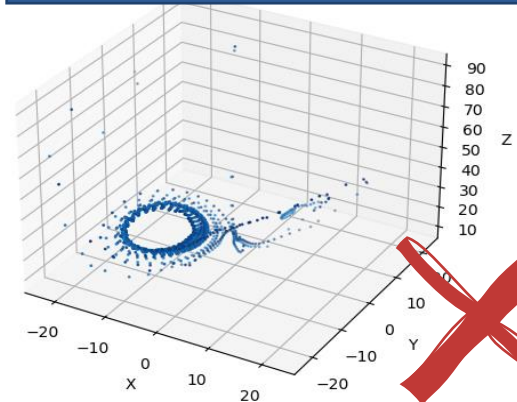
横断リアプノフ指数が負
同期状態から分離する指数

- 一つでも正
⇒再構成失敗(右上)
- 横断リアプノフ指数の求め方
リザーブ空間の次元は
元の相空間よりはるかに多いため
余分なLSが計算される
⇒この余分なLSが横断リアプノフ指数


ローレンツ方程式の時系列
真のLS(0.91, 0, -14.6)




LS=(1.6, 0.23, 0.015, ...) の予測結果



LS=(0.94, 0.03, -0.070, ...) の予測結果



LS=(0.92, 0.00059, -0.033, ...) の予測結果



アトラクタ再構成の5条件

1. 状態の出力可能性
リザー空間の次元 \gg 観測空間の次元

2. ESP (RCの持つ性質)

3. 弱い一般化同期
(連続同期関数 ϕ が存在)

4. 正、零Lyapunovスペクトラムが一致


5. 同期状態は安定
⇒ 横断リアプノフ指数が負
⇒ 横断リアプノフ指数はLyapunovスペクトラムから計算可能

本研究の着眼点

Lyapunovスペクトラム
を調整できれば
アトラクタ再構成できそう

- LyapunovスペクトラムはHyperparameterに依存
その依存性は連続

LSを調整する
Hyperparameter tuning



Hyperparameter
(リザーバーのノード数: N_{res})

課題

- LSはHyperparameterにブラックボックス的に依存
- LSの評価・計算コストが高い

LSを調整する Hyperparameter tuning 方法

- ベイズ最適化、TPE (tree-structured Parzen estimator) [4]
効率的なHyperparameter探索の手法
- 損失関数 E_{cost} を最小化するように探索

$$E_{\text{cost}} = \sum_{1 \leq k \leq j} \frac{a_k (\lambda_k - \hat{\lambda}_k)^2}{1} + \frac{b \chi_{\lambda_{j+1} \geq 0} (\hat{\lambda}_{j+1}) \hat{\lambda}_{j+1}}{1}$$

$(\lambda_j \geq 0, \lambda_{j+1} < 0)$
 $a_k, b > 0$ の定数
本研究では全て1

条件④

正、零LSのうち
真の値との誤差

条件⑤

横断 Lyapunov 指数のうち
正のものが存在する
 $\Rightarrow \hat{\lambda}_{j+1}$ は正の値を取る
 \Rightarrow この項は正の値をもつ

Lyapunovスペクトラムを調整するTuningプロセス

構築

Hyperparameterに基づいて
RCを構築
同期状態まで時間発展

探索

損失関数 E_{cost} から
次に探索するHyperparameter
をベイズ最適化、TPEで決定

学習

出力層 W_{out} を学習データを用いてリッジ回帰で学習

評価

学習済みの出力層と
同期状態のRCから
Lyapunovスペクトラムを計算
損失関数 E_{cost} で評価

ベイズ最適化、TPEでTuning可能


Lorenz方程式

$$\dot{x} = 10(y - x),$$

$$\dot{y} = x(28 - z) - y,$$

$$\dot{z} = xy - 8z/3.$$

サンプリング間隔 $\Delta t = 0.02$
4 次の Runge-Kutta 法で
データを生成



Trial=0のLS

0.156
-0.0175
-0.297

Trial=16のLS

1.02
0.0606
-0.148

Trial=64のLS

0.916
0.00944
-0.0859

真のLS

0.91
0
-14.6

提案手法でアトラクタ
再構成の条件を達成


4. 正、零LSの誤差 小
5. 横断 Lyapunov 指数
は全て 負

実験結果(研究目的の達成：アトラクタ再構成の達成の確認)

Tuningでアトラクタ再構成が達成！


Trial=0のLS

0.156
-0.0175
-0.297




Trial=16のLS

1.02
0.0606
-0.148



Trial=64のLS


0.916
0.00944
-0.0859



Trial=16,64ともに
再構成達成に見える

LSの誤差が小さいことで
何か違いはあるか??

真の時系列



実験結果(本研究の副次的成果)

提案手法で条件を達成

4. 正、零LSの誤差 小
5. 横断 Lyapunov 指数
は全て 負

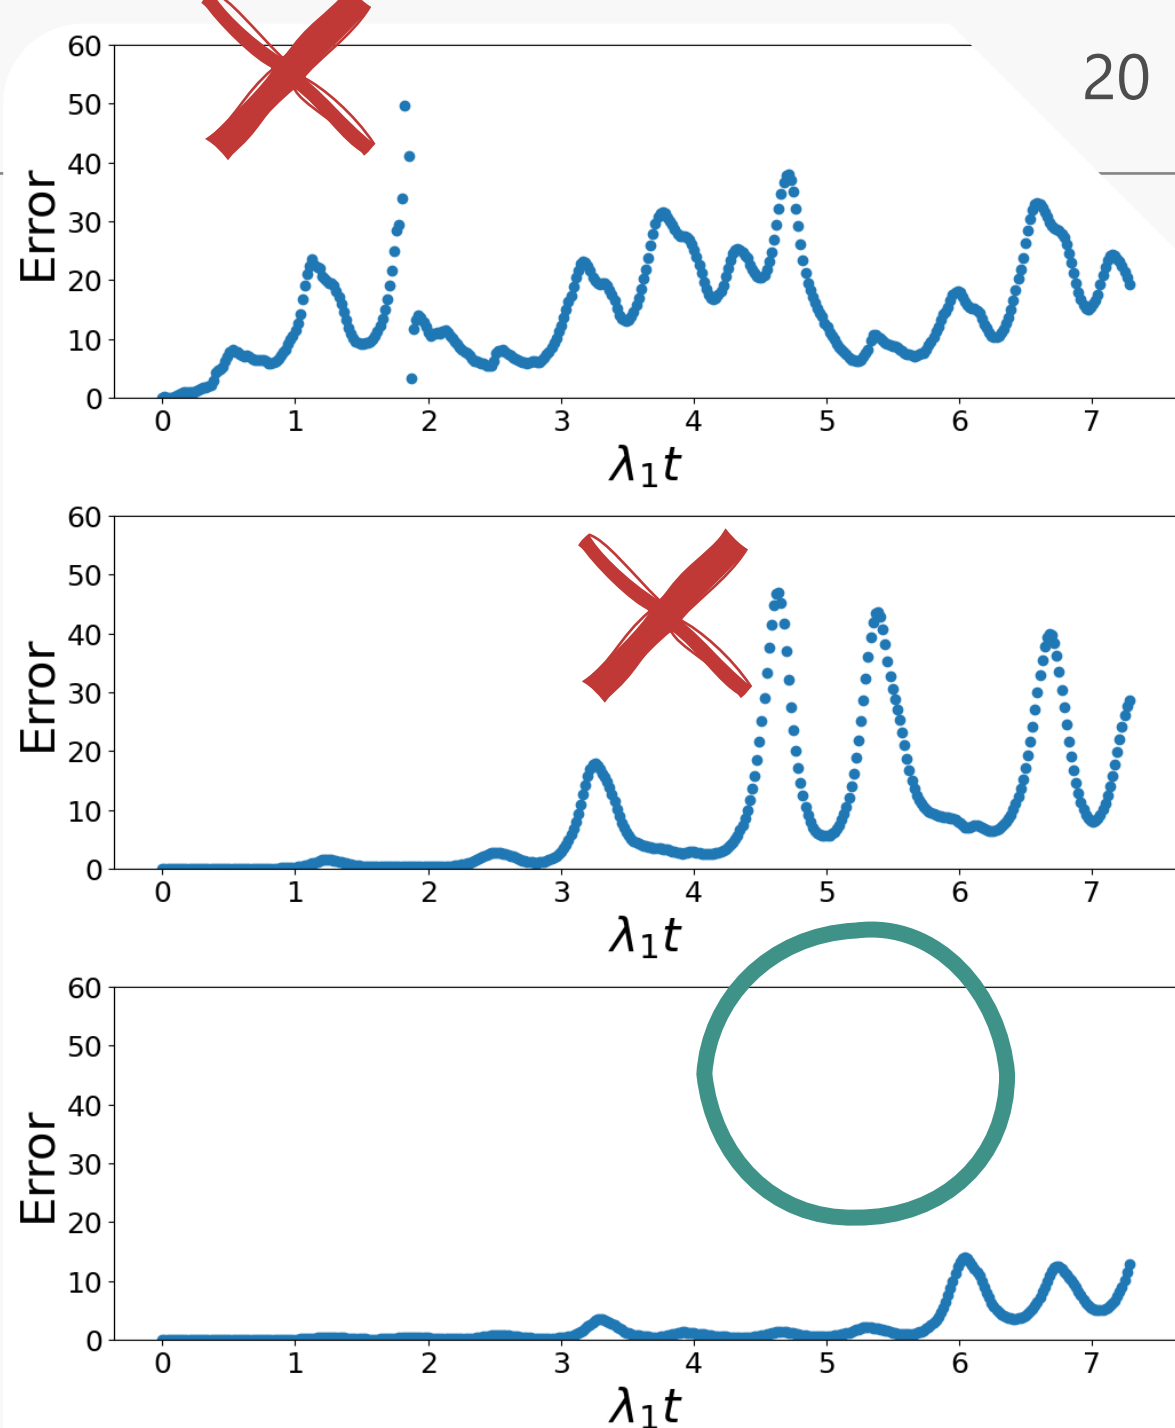


アトラクタ再構成!
&
短期予測精度向上!

Trial=0

Trial=16

Trial=64



- 【目的】
リザーバーコンピューティングによるカオス力学系の時系列予測において、アトラクタ再構成が達成されるように最適化すること。
- 【提案手法】
Lyapunovスペクトラム、横断リアプノフ指数から損失関数を設計
ベイズ最適化（TPE）でHyperparameter tuning
- 【結果】
提案手法で最適化したリザーバーコンピュータは
アトラクタ再構成を達成、Tuningは実行可能。
 - 短期予測の精度の向上
 - より少ないノード数でも予測精度を維持できる

カオス力学系のモデルフリーな予測

$$\frac{dx}{dt} = f(x(t))$$


決定論的法則 未知

十分な長さの
データ列のみ

Lyapunovスペクトラム
を精度よく近似[5]

提案手法で
Tuning


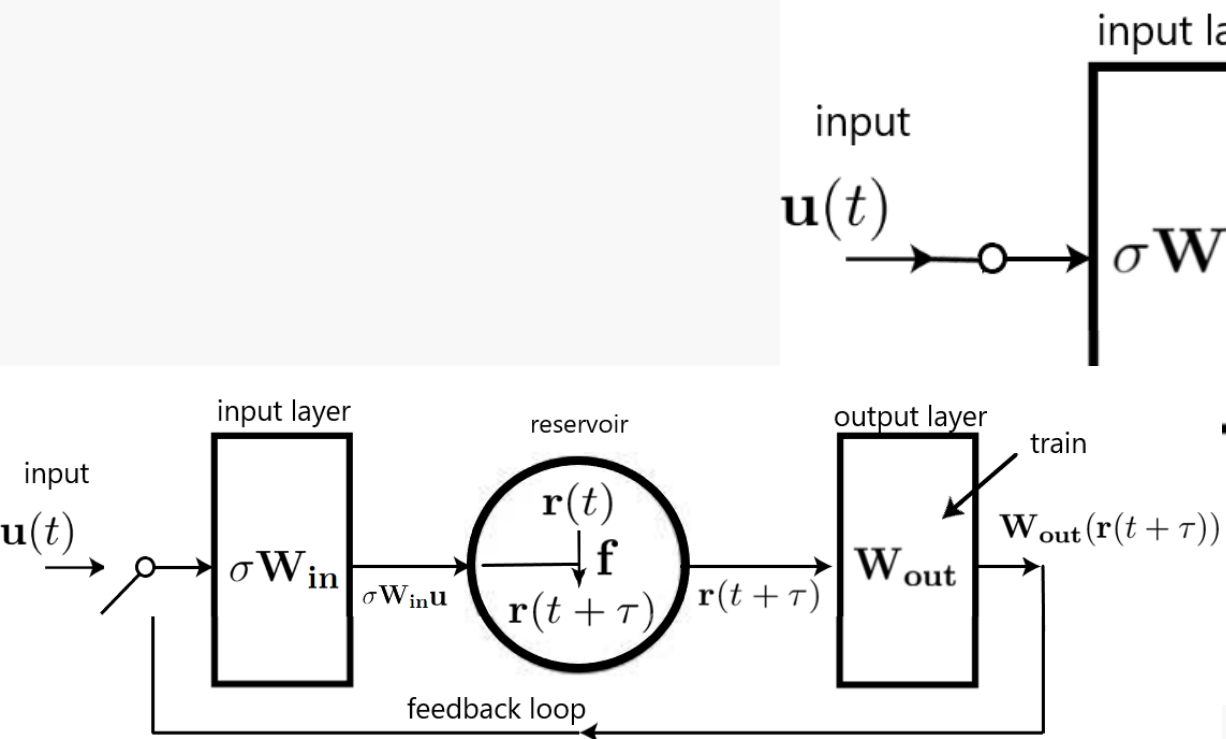
社会・自然界の
様々な系で応用できる



[5]M. Sano and Y. Sawada. Physical Review Letters (1985)

Listening

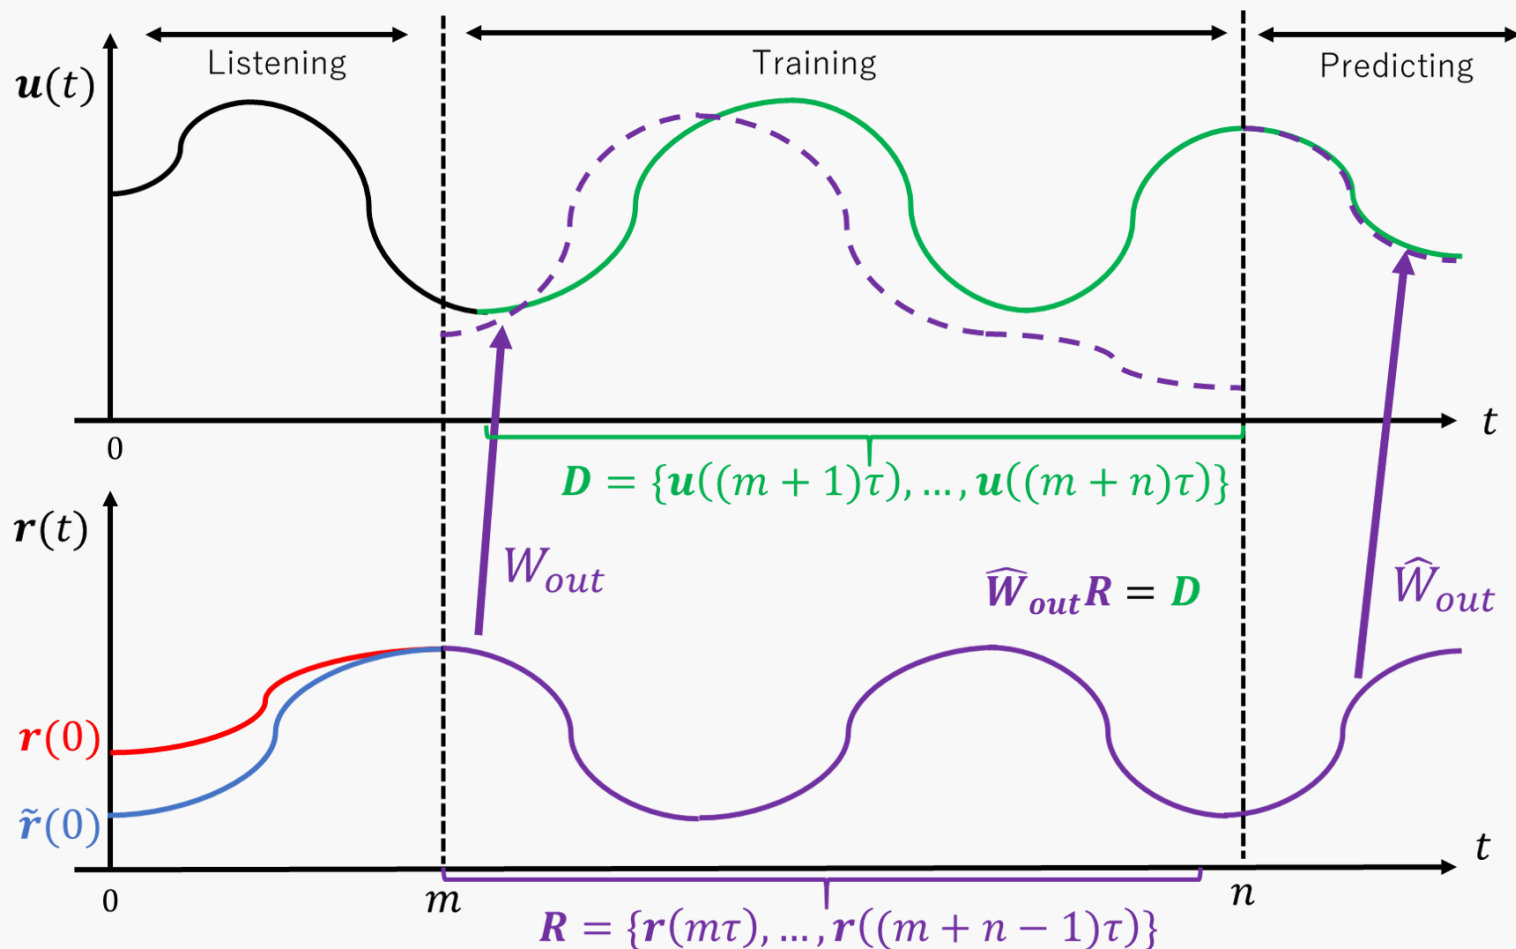
$$\begin{aligned} \mathbf{r}(t + \tau) &= (1 - \alpha)\mathbf{r}(t) + \alpha \mathbf{f}[\mathbf{r}(t), \mathbf{u}(t)] \\ &= (1 - \alpha)\mathbf{r}(t) + \alpha \tanh[\mathbf{W}_{\text{res}}(t) + \sigma \mathbf{W}_{\text{in}} \mathbf{u}(t) + 1] \end{aligned}$$



Training, Predicting

$$E_{\text{RR}} = \frac{1}{2} \|D - \mathbf{W}_{\text{out}} \mathbf{R}\|_{\text{F}}^2 + \frac{\beta}{2} \|\mathbf{W}_{\text{out}}\|_{\text{F}}^2$$

$$\hat{\mathbf{W}}_{\text{out}} = D R^{\top} (R R^{\top} + \beta I)^{-1}$$



$$\begin{aligned} \mathbf{r}(t + \tau) &= (1 - \alpha) \mathbf{r}(t) + \alpha \mathbf{f}[\mathbf{r}(t), \hat{\mathbf{W}}_{\text{out}} \mathbf{r}(t)] \\ &= (1 - \alpha) \mathbf{r}(t) + \alpha \tanh[\mathbf{W}_{\text{res}}(t) + \sigma \mathbf{W}_{\text{in}} \hat{\mathbf{W}}_{\text{out}} \mathbf{r}(t)] \end{aligned}$$

同期状態からLS計算

$$\lambda_k = \lim_{n \rightarrow \infty} \frac{1}{n} \log ||D_{\mathbf{x}(0)} \mathbf{g}^n \mathbf{h}_k||$$

$$\begin{aligned} \mathbf{r}(t + \tau) &= \mathbf{g}(\mathbf{r}(t)) \\ &= (1 - \alpha)\mathbf{r}(t) + \alpha \mathbf{f}[\mathbf{r}(t), \hat{\mathbf{W}}_{\text{out}} \mathbf{r}(t)] \\ &= (1 - \alpha)\mathbf{r}(t) + \alpha \tanh[\mathbf{W}_{\text{res}}(t) + \sigma \mathbf{W}_{\text{in}} \hat{\mathbf{W}}_{\text{out}} \mathbf{r}(t) + \mathbf{1}] \\ &= (1 - \alpha)\mathbf{r}(t) + \alpha \tanh[\mathbf{W}_{\text{all}} \mathbf{r}(t) + \mathbf{1}] \end{aligned}$$

$$\begin{aligned} D\mathbf{g}(\mathbf{r}(t)) &= (1 - \alpha)\mathbf{I} + \alpha D\mathbf{f}[\mathbf{r}(t), \hat{\mathbf{W}}_{\text{out}} \mathbf{r}(t)] \\ &= (1 - \alpha)\mathbf{I} + \alpha \mathbf{W}_{\text{all}}^\top (\tanh)'[\mathbf{W}_{\text{all}} \mathbf{r}(t) + \mathbf{1}] \\ &= (1 - \alpha)\mathbf{I} + \alpha \mathbf{W}_{\text{all}}^\top (\mathbf{I} - \tanh^2[\mathbf{W}_{\text{all}} \mathbf{r}(t) + \mathbf{1}]) \end{aligned}$$




表 2.1: アトラクタの分類

	点 アトラクタ	周期 アトラクタ	準周期 アトラクタ	ストレンジ アトラクタ
アトラクタの 幾何学的構造	点	閉曲線	k-トーラス	フラクタル構造
アトラクタ上の 振る舞い	静止	周期的	準周期的	カオス
n 次元相空間に おけるアトラクタ の次元	0	1	n 未満の整数 k	n 未満の非整数
n 次元相空間の 場合の Lyapunov スペクトラム	$\lambda_i = 0$ ($i = 1, \cdots, n$)	$\lambda_i = 0$ ($i = 1$) $\lambda_i < 0$ ($i = 2, \cdots, n$)	$\lambda_i = 0$ ($i = 1, \cdots, k$) $\lambda_i < 0$ ($i = k + 1, \cdots, n$)	$\lambda_i > 0$ ($i = 1, \cdots, k - 1$) $\lambda_i = 0$ ($i = k$) $\lambda_i < 0$ ($i = k + 1, \cdots, n$)

表 1.1: 固定する hyperparameter と hyperparameter の探索範囲

	意味	Tuning 範囲 or 固定した値
N_{res}	リザーバーのノード数	閉区間 $[400, 1000]$ 内の間隔が 100 の整数値
σ	入力強度	閉区間 $[0.1, 2.0]$
d	リザーバーの結合密度	閉区間 $[0.1, 2.0]$
ρ	\mathbf{W}_{res} のスペクトル半径	閉区間 $[0.1, 1.0]$
α	リザーバーの leak 率	閉区間 $[0.99, 1.0]$
β	Ridge 回帰の正則化項	閉区間 $[0, 0.1]$
f	リザーバーの活性化関数	tanh で固定
m	Listen Step 数	2000 で固定
n	Train Step 数	8000 で固定
n'	Lyapunov 指数計算 Step 数	5000 で固定